

Trabalho da matéria Fundamentos de Inteligência Artificial

Mecanismo do Viés:

A seleção restrita de dados **limita** a diversidade de exemplos que o algoritmo **observa** durante o treinamento. Como consequência, o modelo **aprende** padrões incompletos e **assume** que eles **representam** toda a realidade. Quando o conjunto de dados **prioriza** apenas um tipo de exemplo e **exclui** outros, o algoritmo **replica** essa assimetria e **produz** classificações distorcidas. Assim, o sistema **transforma** um recorte parcial do mundo em uma regra geral, o que **corrompe** a lógica de decisão do modelo e **gera** previsões enviesadas.

Consequência Social:

Quando o sistema **associa** pessoas negras mal vestidas à categoria “feio” e pessoas brancas com roupa formal à categoria “bonito” (viés proposto aqui), ele **reforça** estereótipos raciais e sociais. O indivíduo afetado **sente** desvalorização e invisibilidade ao perceber que o algoritmo **julga** sua imagem a partir de um padrão injusto. Em contextos profissionais, essa lógica **reduz** oportunidades e **reproduz** desigualdades já presentes na sociedade.

Ação Mitigadora:

Uma abordagem de *Human-in-the-loop* **introduz** supervisão humana contínua no processo de curadoria e validação dos dados. Antes da implementação do modelo, uma equipe diversa **analisa**, **revisa** e **equilibra** o conjunto de dados para garantir representatividade adequada. Durante o treinamento, especialistas **monitoram** os resultados e **identificam** padrões de erro que **indicam** viés. Quando esses problemas **aparecem**, os responsáveis **ajustam** o dataset e **reavaliam** o modelo. Esse processo **combina** a capacidade computacional do algoritmo com o julgamento crítico humano e **promove** maior equidade nas decisões do sistema.